## Tema d'esame di Statistica e analisi dei dati

Prova scritta del 16 gennaio 2019

Considerate una generica variable aleatoria X che assume esclusivamente i valori -1 e 1.

X Quanto vale la probabilità P(X=-1)? Scrivete, sotto forma di tabella, la funzione di X Quanto vale la probabilità di X P/2Indichiamo con p la probabilità P(X = 1).

massa di probabilità di X. 8/2

 ${\mathbb Z}$ . Calcolate, in funzione di p, il valore atteso  ${\rm E}(X).$ 

 $\mathcal{S}$ . Esprimete p in funzione di E(X).

 ${\mathcal A}$ . Quali valori può assumere la variabile aleatoria  $Y=g(X)=X^2$  ?

5. Quanto vale E(Y)?

 $\mathscr{C}$ . Calcolate, in funzione di p, la varianza di X.

 ${\mathscr A}.$  Scrivete la trasformazione  $h:{\mathbb R}\mapsto{\mathbb R}$  da applicare a X per ottenere una variabile bernoulliana Z = h(X).

8. Fissiamo, solo in questo punto, p = 0.7.

&1. Disegnate a mano due grafici qualitativi che descrivano rispettivamente le funzioni di massa di probabilità di X e di Z.

8/2. Disegnate a mano due grafici qualitativi che descrivano rispettivamente le funzioni di ripartizione di X e di Z.

## Esercizio 1

1. Indichiamo con  $\overline{X}_{(n)}$  la media campionaria di un campione casuale  $X_1,\dots,X_n$  estratto dalla popolazione X studiata nell'esercizio precedente.

1.1. Esprimete il valore atteso di  $\overline{X}_{(n)}$  in funzione di p.

1.2. Esprimete la varianza di  $\overline{X}_{(n)}$  in funzione di Var(X).

1.3. Esprimete la varianza di  $\overline{X}_{(n)}$  in funzione di  $p \in n$ .

2. Controllate che  $T_n = \frac{1+\overline{X}_{(n)}}{2}$  è uno stimatore non distorto per il parametro p.

3. Indicata con  $\Phi$  la funzione di ripartizione della variabile normale standard, verificate che per  $n \gg 1$  vale la seguente relazione:

$$P(|T_n - p| \le 0.05) \approx 2\Phi\left(\frac{0.1\sqrt{n}}{2 \cdot \sqrt{p(1-p)}}\right) - 1.$$

Sia G una variabile esponenziale di parametro  $\nu$ .

1. Quali valori può assumere G?

2. Esprimete, in funzione di  $\nu$ , la densità di probabilità  $f_G$ 

3. Fissato, solo in questo punto,  $\nu=0.1,$  tracciate il grafico di  $f_G.$ 

4. Esprimete la deviazione standard  $\sigma_G$  di G in funzione del valore atteso  $\mathrm{E}(G)$ 

5. Di seguito sono mostrati i grafici della funzione di ripartizione di due variabili esponenziali di parametri differenti. Quale dei due grafici corrisponde alla variabile di valore atteso maggiore? Giustificate la risposta.

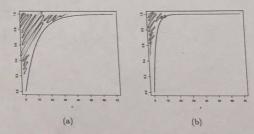


Figura 1: Funzione di ripartizione di due variabili esponenziali

## Esercizio 3

Collegatevi al sito upload.di.unimi.it, selezionate l'esame di Statistica e analisi dei dati per l'appello odierno e scaricate il file carsharing.csv. Questo file contiene le seguenti informazioni raccolte da un servizio di car sharing riguardo a singoli utilizzi dei veicoli della propria flotta:

• CarIdentifier: identificatore del veicolo;

• TimeFrame: fascia oraria in cui il veicolo è stato utilizzato;

• RushHour: indica se la fascia oraria corrisponde a un orario di punta, usando un'ovvia codifica binaria:

• PremiumCustomer: indica se l'utente che ha utilizzato il veicolo è iscritto al programma Premium (usando anche in questo caso una semplice codifica binaria);

• Distance: lunghezza del tragitto (espressa in km);

• Time: tempo impiegato a percorrere il tragitto (espresso in minuti).

In questo file il carattere ";" separa le colonne e i numeri reali sono stati registrati usando il carattere "," come separatore dei decimali.

1. Quanti casi contiene il file?

- 2. Analizziamo l'utilizzo del servizio di car sharing nelle diverse fasce orarie (carattere *TimeFrame*) a realizziamo l'utilizzo del servizio di car sharing nelle diverse fasce orarie (carattere *RushHour*). TimeFrame) e negli orari di maggior o minor traffico (carattere RushHour).
- 21. Il carattere TimeFrame è nominale, ordinale o scalare? Giustificate la risposta.
- 22. In quante fasce orarie è stata suddivisa una giornata?
- 28. In quali fasce orarie il servizio di car sharing è stato maggiormente utilizzato?
- 24. Calcolate la tabella delle frequenze congiunte di TimeFrame e RushHour. 25. Leggendo la tabella calcolata al punto precedente determinate quali sono le fasce
- orarie che corrispondono all'ora di punta.
- 3. Consideriamo, solo in questo punto dell'esercizio, i clienti che hanno aderito al programma Premium (Premium=1).
- 3/2. Fornite una stima della distanza media percorsa in un tragitto da un cliente che ha aderito al programma Premium.
- 38. Stimate la probabilità p che un nuovo cliente si iscriva al programma Premium.
- 3.4. Quale stimatore avete utilizzato al punto precedente?
- 3%. Fornite un'approssimazione della probabilità di compiere nella stima di p un errore al più uguale a 0.05.
- 4. Ritorniamo a considerare il dataset completo e studiamo la distanza percorsa in ciascun utilizzo del servizio (carattere Distance).
- 1.1. Tracciate il boxplot di tale carattere.
- 42. In base all'aspetto del grafico ottenuto al punto precedente, determinate quali sono gli indici di centralità e di dispersione che meglio caratterizzano la distanza percorsa, calcolandone il valore.
- 4.3. Riscontrate una relazione tra la distanza percorsa e il tempo impiegato? In caso affermativo, caratterizzate tale relazione. In ogni caso giustificate la vostra risposta mostrando un grafico.
- X.4. Calcolate l'indice di correlazione tra la distanza e il tempo. Il valore ottenuto supporta la risposta che avete dato al punto precedente?
- 5. Analizziamo ora la distanza percorsa in ciascun utilizzo del servizio negli orari di punta (RushHour=1).
  - 5/1. Tracciate un grafico rappresentativo della distribuzione della distanza percorsa negli
  - 52. È plausibile affermare che negli orari di punta la distanza segue una legge normale? Giustificate la risposta
  - 5/3. Stimate il valore atteso e la deviazione standard della distanza negli orari di punta.
  - 54. Sapreste suggerire un modello probabilistico per la distanza percorsa negli orari di punta?
  - 56. Le stime del valore atteso e della deviazione standard che avete appena calcolato sono compatibili con il modello che avete proposto? Giustificate la risposta.