# Tema d'esame di Statistica e analisi dei dati

### Prova scritta del 2 luglio 2018

#### Esercizio 0

- 1. In Figura 1 è mostrata la funzione di ripartizione di due variabili casuali X e Y. In Figura 2 è mostrata la funzione densità di probabilità delle medesime due variabili, ma non è precisato quale grafico competa a quale variabile. Si completi la figura con il riferimento alla variabile opportuna.
- 2. Quale delle due variabili ha valore atteso maggiore? Si giustifichi la risposta.
- 3. Il valore 2 a quale percentile di X corrisponde? A quale percentile di Y corrisponde?
- 4. Qual è il cinquantesimo percentile di X? Qual è il cinquantesimo percentile di Y?
- 5. Quanto vale la probabilità P(2 <  $X \le 5$ )? Quanto vale la probabilità P(2 <  $Y \le 5$ )?
- 6. Per la variabile Y si dica se la media è maggiore, minore oppure uguale alla mediana.

#### Esercizio 1

Sia X una variabile casuale esponenziale di parametro  $\nu$ .

- 1. Si esprima, in funzione  $\nu$ , la funzione densità di probabilità di X.
- 2. Si esprimano, in funzione  $\nu$ , il valore atteso e la deviazione standard di X

Sia  $X_1, \dots, X_n$  un campione casuale estratto dalla popolazione X.

- 3. Si proponga uno stimatore, chiamiamolo  $T_n$ , del valore atteso di X.
- 4. Si proponga uno stimatore, chiamiamolo  $R_n$ , del parametro  $\nu$ .

## Esercizio 2

Presso un ambulatorio veterinario un gruppo di cani viene seguito regolarmente, e a oggi la situazione dello stato di salute dei pazienti a quattro zampe è documentata in un file che contiene le seguenti informazioni:

- Cartella: numero della cartella clinica,
- IP: indica se il paziente soffre di ipertensione,
- · GravitaIP: gravità dell'ipertensione,
- · EtaAnni: età (espressa in anni),

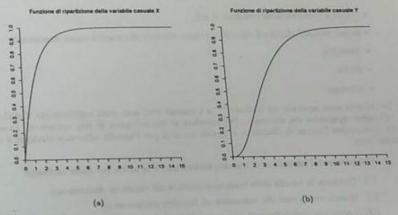


Figura 1: Funzione di ripartizione: (a) della variabile X, (b) della variabile Y

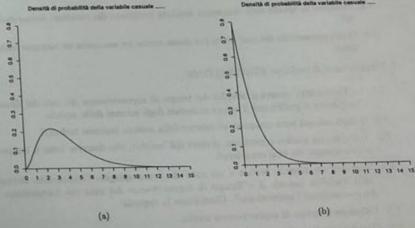


Figura 2: Funzioni densità di probabilità : which is which?

- MORTE: indica se il cane è ancora in vita oppure è deceduto,
- MC: indica se il cane è deceduto a causa di problemi cardiaci (morte cardiaca),
- SURVIVALTIME: tempo di sopravvivenza a partire dalla prima visita, espresso in giorni, cioè tempo intercorso tra la prima visita e il decesso oppure tempo intercorso tra la prima visita e oggi se il cane è ancora in vita,
- Antiaritmico: indica se il cane assume un farmaco per l'aritmia,
- · Terapia: indica il numero di farmaci somministrati,

- PesoKg: peso del cane (espresso in kg),
- e alcune variabili cliniche il cui valore è stato determinato tramite esami strumentali:
- · OndaEA,
- · EDVI,
- · Allodiast

Le colonne sono separate dal simbolo ";" e i numeri reali sono stati registrati con il simbolo "," come separatore dei decimali. Per accedere al file collegarsi al sito upload.di.unimi. it, selezionare l'esame di Statistica e analisi dei dati per l'appello odierno e scaricare il file cani.csv.

- 1. Consideriamo l'assunzione di farmaci antiaritmici e la morte per cause cardiache.
  - 1.1. Produrre la tabella delle frequenze assolute del carattere Antiaritmico.
  - 1.2. Quanti sono i cani che assumono un farmaco antiaritmico?
  - 1.3. Il carattere Antiaritmico è categorico. Volendolo convertire in un carattere numerico, con quale valore numerico mettereste in corrispondenza valore "SI"? Con quale il "NO"?
- 1.4. Produrre la tabella delle frequenze assolute congiunte dei caratteri Antiaritmico e MC.
- 1.5. Quale percentuale dei cani morti per cause cardiache assumeva un farmaco antiaritmico?
- 2. Consideriamo il carattere SURVIVALTIME.
  - 2.1. La Figura 3(a) mostra il boxplot del tempo di sopravvivenza dei cani del dataset. Completare il grafico con il valore numerico degli estremi della scatola.
- 2.2. Quanti animali sono compresi all'interno della scatola (estremi inclusi)?
- 2.3. Tracciare un grafico opportuno, diverso dal boxplot, che descriva bene il tempo di sopravvivenza dei cani considerati.
- 2.4 Suggerite un modello teorico a voi noto che possa spiegare l'andamento aleatorio della variabile casuale X="Tempo di sopravvivenza dei cani che frequentano (o frequenteranno) l'ambulatorio". Giustificate la risposta.
- 2.5. Calcolate il tempo di sopravvivenza medio.
- 2.6. Calcolate la deviazione standard del tempo di sopravvivenza.
- 2.7. Il modello che avete suggerito dovrebbe presentare uno (o più) parametri. Fornitene una stima numerica.

### Esercizio 3

Create una variabile che contenga la parte di dataset relativa ai cani morti e considerando soltanto i casi in cui sia il carattere MC, sia il carattere OnduEA non siano mancanti. Nel presente esercizio le domande si riferiranno esclusivamente a questo sottoinsieme di casi.

- 1 L'OndaEA è un carattere scalare oppure ordinale?
- 2. Produrre il boxplot relativo al carattere OndaEA.

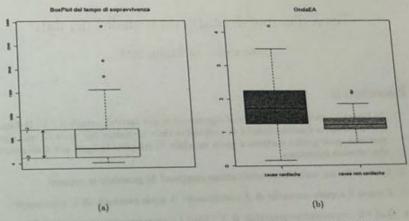


Figura 3: (a) boxplot del tempo di sopravvivenza; (b) boxplot di OndaEA

- Il grafico ottenuto dovrebbe mostrare la presenza di un outlier. Determinare il valore di OndaEA per tale individuo.
- 4. L'outlier individuato è un cane morto per cause cardiache oppure no?

In Figura 3(b) sono messe a confronto le distribuzioni del carattere OndaEA nei due gruppi di cani deceduti per cause cardiache e per altre cause. Ci si convince facilmente del fatto che l'OndaEA appare molto diversa nei due gruppi, e ciò ci suggerisce che potremmo utilizzare l'OndaEA come criterio di discriminazione tra la morte per cause cardiache e quella per altre cause.

- Si controlli che il terzo quartile, chiamiamolo s, dell' Onda EA relativamente ai cani deceduti per cause non cardiache è 1.41.
- 6. Quanti sono i cani deceduti per cause cardiache? Quanti per altre cause?
- 7. All'interno del dataset, quanti cani deceduti per cause cardiache avevano il valore di OndaEA≥ s? E quanti cani deceduti per cause non cardiache avevano il valore di OndaEA< s?</p>
- 8. Utilizziamo il valore s trovato al punto 5. come soglia per un classificatore binario che discrimina tra morte cardiaca e morte non cardiaca: il classificatore classificherà come morte cardiaca i casi per i quali OndaEA≥ s e come morte non cardiaca i casi per i quali OndaEA< s.</p>

Calcolare la sensibilità e la specificità di questo classificatore.