Tema d'esame di Statistica e analisi dei dati

Prova scritta del 20 settembre 2018

Esercizio 0

Considerate un esperimento che può avere due esiti possibili, che chiameremo successo e insuccesso. Sia X la variabile casuale che assume il valore 1 se eseguendo l'esperimento si ottiene un successo, e assume il valore 0 altrimenti. Indichiamo con $p \in (0,1)$ la probabilità di ottenere un successo.

- 1. Che legge segue la variabile X?
- $\not p$. Esprimete, in funzione di p, la deviazione standard di X.
- ${\mathcal F}$ Eseguiamo $k\in \mathbb{N}$ prove dell'esperimento considerato in condizioni di indipendenza. Esprimete, in funzione di k e p, la probabilità di ottenere esattamente $x\in \mathbb{N}$ successi.
- 4. Consideriamo, solo in questo punto, il caso particolare k=50 e p=0.3, e la variabile casuale Y="numero di successi ottenuti nelle k prove sopra descritte". Tracciate il grafico della funzione massa di probabilità di Y.
- 5/Fornite la definizione di stimatore per un parametro θ di una popolazione Z.

Sia X_1,\dots,X_n un campione casuale estratto dalla popolazione X descritta nei punti precedenti.

- \mathscr{S} . Proponete uno stimatore T_n non distorto per il parametro p.
- 7. Per $n \gg 1$ si controlli che:

 $P(-\epsilon < T_n - p < \epsilon) \approx 2\Phi(\epsilon \cdot \sqrt{n}/\sigma) - 1$

dove Φ è la funzione di ripartizione di una normale standard e σ è la deviazione standard della popolazione X.

Esercizio 1

Il file finanziamenti.csv contiene alcune informazioni riguardo a progetti finanziati nell'anno corrente:

- id: identificatore del progetto,
- TemaPrioritario: codice che indica il tema prioritario del progetto,
- FONTE: area tematica del progetto,
- CATEGORIA: categoria del progetto,
- CodiceCategoria: codice numerico della CATEGORIA,

Figu di I

finar

- 64. Selezionate i progetti di tipo A che hanno ricevuto un finanziamento provinciale compreso tra i 200 e i 1000 euro, estremo sinistro incluso, e salvate questa parte di dataset in una variabile chiamata selezione_progetti_a.
- 6.2. Tracciate un istogramma del finanziamento provinciale di tali progetti, imponendo che le classi abbiano ampiezza 100 euro.
- 6.3. Tracciate anche il boxplot per la medesima quantità.
- Tra i due grafici appena prodotti, quale ritenete maggiormente informativo? Giustificate la risposta.
- 6.5. Relativamente a tali progetti, qual è stato l'importo medio finanziato dalla provincia? Quale la deviazione standard?
- 6.6. Quanti hanno ricevuto un finanziamento provinciale compreso tra i 500 e i 700 euro?
- 6.4. Esiste una evidente relazione tra finanziamento provinciale e spese sostenute. Descrivete tale relazione nel modo più dettagliato possibile, utilizzando un indice numerico e un metodo grafico.
- 6.8. Nella relazione avrete notato la presenza di almeno un progetto che si discosta notevolmente dall'andamento più generale. Eliminate tali progetti dall'insieme dei dati e rispondete nuovamente alle domande del punto precedente.

Esercizio 2

Ritorniamo al dataset completo. I dati ivi presenti costituiscono una fotografia della situazione contabile dopo un anno dall'assegnazione del finanziamento, in cui il valore dell'attributo *TotSpese* è mancante nel caso in cui non siano ancora state sostenute spese per il relativo progetto.

- 1. Quanti sono i progetti che non hanno ancora sostenuto spese?
- 2. Siamo interessati a stimare la probabilità che, a distanza di un anno dall'assegnazione del finanziamento, non si siano ancora sostenute spese. Fornite una stima di tale probabilità.
- 3. Consideriamo lo spazio campionario $\Omega = \mathbb{R}^+ \cup \{NA\}$ che codifica i valori possibili per l'attributo TotSpese. Tenuto conto del fatto che una variable aleatoria è una funzione $X:\Omega \mapsto \mathbb{R}$, definite opportunamente X in modo da legarla all'evento "a un anno dall'assegnazione del finanziamento il progetto non ha sostenuto spese".
- \checkmark . Che legge segue X?
- 5. Fornite una stima del parametro di tale legge, precisando una sola cifra decimale.
- 6. Siamo disposti ad accettare di "sbagliare" nella stima con una probabilità del 95%. Qual è il margine di errore che dobbiamo tollerare?
- 7. Tale errore riguarda la prima cifra decimale oppure la seconda?
- 8. Pensando di finanziare nel prossimo futuro altri 50 progetti, date una stima della probabilità che, trascorso una anno dall'assegnazione del finanziamento, esattamente 10 di essi non abbiano ancora sostenuto spese.

- FinProvincia: entità del finanziamento da parte della provincia,
- FinRegione: entità del finanziamento da parte della regione,
- TotSpese: spese sostenute per il progetto.

Le colonne sono separate dal simbolo ";" e i numeri reali sono stati registrati con il simbolo "," come separatore dei decimali. Per accedere al file, collegatevi al sito upload.di.unimi. it, selezionate l'esame di Statistica e analisi dei dati per l'appello odierno e scaricate il file finanziamenti.csv.

- A. Il carattere CodiceCategoria è nominale, ordinale o scalare? Giustificate la risposta.
- Z Calcolate la tabella delle frequenze assolute del carattere UNITA.
- Z Tracciate un grafico opportuno per descrivere il carattere UNITA.
- 4. La Figura 1 mostra la funzione di ripartizione empirica per un sottoinsieme delle osservazioni relativi al carattere *TotSpese*, in cui gli importi sono indicati in centinaia di migliaia di Euro. Leggendo esclusivamente il grafico:
 - 4.1. indicate quale sottoinsieme di osservazioni è stato utilizzato;
 - 42. specificate quale percentuale delle osservazioni visualizzate assume un valore compreso tra uno e due milioni di Euro.

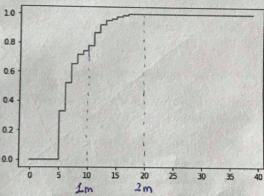


Figura 1: Il grafico della funzione di ripartizione empirica per un sottoinsieme delle osservazioni di *TotSpese*.

- 5. Prendiamo in considerazione la quota di finanziamento erogata dalla Provincia.
 - M. Create una variabile (chiamatela progetti_a, per indicare i progetti di tipo A) che contenga la parte di dataset relativa ai progetti per i quali la quota provinciale di finanziamento è minore di quella regionale, e un'altra (chiamata progetti_b, per indicare i progetti di tipo B) che contenga la parte di dataset relativa ai progetti restanti.
 - 5/2. Quanti sono progetti di tipo A? Quanti sono progetti di tipo B?

e insuc-

ndenza. cessi.

ariabile I grafico

i punti

andard

l'anno