Luglio 2017

Esercizio 0

1

Completare la tabella dei percentili:

- 15 -> decimo percentile
- 55 -> 30esimo percentile
- 200 -> 50esimo percentile
- x -> 70esimo percentile
- y -> 90esimo percentile

```
x = 200 + (200-55) = 345 y = 200 + (200-15) = 385
```

2

Grafico

In [1]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
```

Esercizio 1

```
In [2]:
```

```
#ESERCIZIO 1.1: Importare i dati (tenendo presente che il separatore di decimali per i
    numeri è la virgola
#e i valori sono separati dal carattere ";") e dire quanti casi sono presenti nel datas
et.
dati = pd.read_csv("BibliotecheQuartiere.csv",sep=";",decimal=",")
dati.columns
dati.count()
len(dati)

Out[2]:
402

In [3]:
#ESERCIZIO 1.2: Da quale anno a quale anno sono stati raccolti i dati?
dati['Anno'].unique()
print("dal 1996 al 2010")
```

dal 1996 al 2010

In [4]:

```
#ESERCIZIO 1.3: Quante sono le biblioteche rionali presenti nel dataset?
#Elencarne i nomi.
print(len(dati['Biblioteca'].unique()))
dt = dati['Biblioteca'].drop_duplicates().sort_values()
dt[:10]
```

73

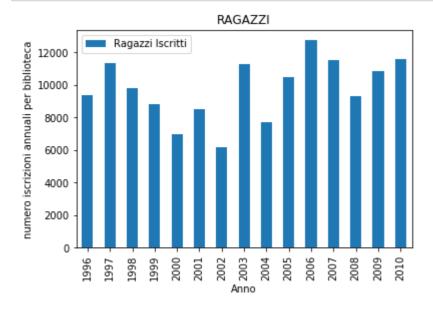
Out[4]:

| 0 | Accursi | 0 | | | | | |
|-------|-----------------------|--------|--------|--|--|--|--|
| 110 | Accursio ³ | * | | | | | |
| 163 | Accursio ³ | * | | | | | |
| 1 | Affori | | | | | | |
| 244 | Affori [;] | * | | | | | |
| 2 | Baggio | | | | | | |
| 218 | Baggio [;] | * | | | | | |
| 191 | Baggio* | | | | | | |
| 3 | Bergamini | | | | | | |
| 246 | Bergamini* | * | | | | | |
| Name: | Riblioteca | dtvne: | ohiect | | | | |

Name: Biblioteca, dtype: object

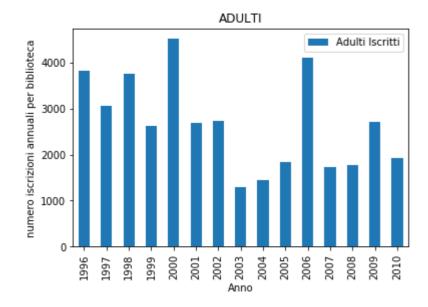
In [5]:

```
#ESERCIZIO 1.4.1: Tracciare il grafico che si ritiene più opportuno per descrivere il n
umero di ragazzi che
#si iscrivono in biblioteca all'anno. Il grafico deve avere il titolo "RAGAZZI" e sul
l'asse opportuno
#(a seconda del grafico che scegliete) deve apparire l'etichetta "numero iscrizioni ann
uali per biblioteca".
ria = dati[['Anno','Ragazzi Iscritti']].dropna().groupby("Anno").sum()
ria.plot.bar()
plt.title("RAGAZZI")
plt.ylabel("numero iscrizioni annuali per biblioteca")
plt.show()
```



In [6]:

```
#ESERCIZIO 1.4.2. Tracciare un grafico analogo che descriva il numero di adulti che si
iscrivono in biblioteca all'anno.
aia = dati[['Anno','Adulti Iscritti']].dropna().groupby("Anno").sum()
aia.plot.bar()
plt.title("ADULTI")
plt.ylabel("numero iscrizioni annuali per biblioteca")
plt.show()
```



In [7]:

```
#ESERCIZIO 1.5.1. Calcolare la media, la deviazione standard e il coefficiente di varia
zione del numero di ragazzi
#che si iscrivono in biblioteca all'anno.
print(ria.mean())
print(ria.std())
print(ria.std()/ria.mean())
```

Ragazzi Iscritti 9759.9224

dtype: float64

Ragazzi Iscritti 1885.754181

dtype: float64

Ragazzi Iscritti 0.193214

dtype: float64

In [8]:

```
#ESERCIZIO 1.5.2. Fare lo stesso per il numero di adulti.
print(aia.mean())
print(aia.std())
print(aia.std()/aia.mean())
```

```
Adulti Iscritti 2670.385333
```

dtype: float64

Adulti Iscritti 1017.060859

dtype: float64

Adulti Iscritti 0.380867

dtype: float64

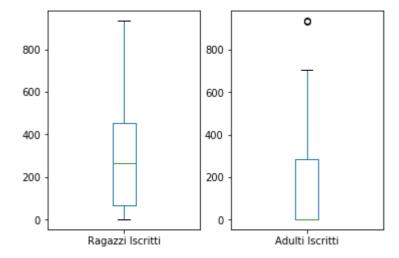
In [9]:

```
#ESERCIZIO 1.5.3 Confrontare la variabilità del numero di iscrizioni di ragazzi rispett
o a quella di adulti
print("Gli adulti iscritti all'anno sono più dispersi rispetto ai ragazzi iscritti")
```

Gli adulti iscritti all'anno sono più dispersi rispetto ai ragazzi iscritti

In [10]:

```
#ESERCIZIO 2:Concentriamoci sull'anno 2000.
#2.1. Tracciare, possibilmente nella stessa figura, il boxplot del numero di ragazzi ch
e si sono iscritti e del numero di
#adulti che si sono iscritti a una biblioteca rionale di Milano (nell'anno 2000).
plt.subplot(1,2,1)
dati[dati['Anno']==2000]['Ragazzi Iscritti'].plot.box()
plt.subplot(1,2,2)
dati[dati['Anno']==2000]['Adulti Iscritti'].plot.box()
plt.show()
```



Esercizio 2

In [11]:

```
#Esercizio 2.2. Utilizzare il risultato del comando summary per rispondere alle seguent
i domande:
#2.1. nell'anno 2000 quale percentuale (circa) di biblioteche ha avuto più di 300 nuovi
ragazzi iscritti?
mask1 = dati["Anno"]==2000
mask2 = dati["Ragazzi Iscritti"]<300
len(dati[mask1 & mask2]["Biblioteca"].get_values())/len(dati["Biblioteca"].unique())</pre>
```

Out[11]:

0.1917808219178082

In [12]:

#2.2. nell'anno 2000 quale percentuale (circa) di biblioteche ha avuto più di 950 nuovi
iscritti?
mask1 = dati["Anno"]==2000
mask2 = dati["Ragazzi Iscritti"]>300
len(dati[mask1 & mask2]["Biblioteca"].get_values())/len(dati["Biblioteca"].unique())

Out[12]:

0.1232876712328767

Esercizio 3

In [13]:

#Esercizio 3.1 Concentriamoci ora sul servizio Bibliobus.
#3.1. Creare una variabile che contiene i soli casi del dataset che si riferiscono alla
biblioteca Bibliobus
bb = dati[dati['Biblioteca'] == "Bibliobus"]

In [14]:

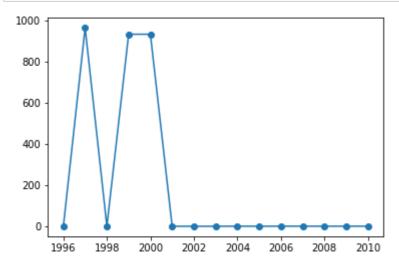
#3.2 Calcolare la tabella delle frequenze congiunte tra l'anno e il totale di nuovi isc
ritti al Bibliobus.
ann_iscritt = pd.crosstab(index=bb["Anno"],columns=bb["Totale Iscritti"])
ann_iscritt.head()

Out[14]:

| Totale Iscritti | 1.03 | 1.094 | 1.1 | 1.117 | 1.13 | 1.314 | 1.34 | 1.345 | 1.37800000000000001 | 1.434000 |
|--------------------|------|-------|-----|-------|------|-------|------|-------|---------------------|----------|
| Anno | | | | | | | | | | |
| 1996 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| 1997 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 1998 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 |
| 1999 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| 2000 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |

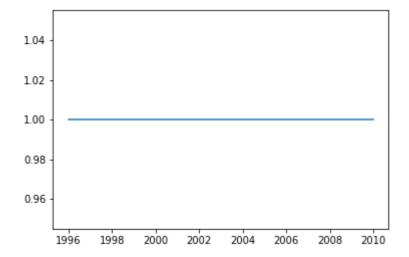
In [15]:

```
#3.3. Tracciare il grafico di dispersione dei caratteri Anno e Totale.Iscritti.
#Siccome in questo caso i dati sono ordinati per anno crescente, rigenerare il grafico
di dispersione collegando
#ciascun punto al successivo tramite una linea spezzata, al fine di evidenziare una ten
denza.
x = bb["Anno"]
y = bb["Totale Iscritti"]
colors = np.random.rand(100)
plt.scatter(x,y)
plt.plot(x,y) #collegare i puntini!!!!
plt.show()
```



In [16]:

```
#3.4. Commentare, anche avvalendosi di strumenti formali, la seguente affermazione:
#"si può notare che nel corso degli anni c'è stato un incremento, seppur modesto, del n
umero di iscrizioni al
#servizio Bibliobus".
ecdf = sm.distributions.ECDF(bb["Totale Iscritti"])
x = bb["Anno"]
y = ecdf(x)
plt.step(x,y)
plt.show()
print("non cresce negli anni")
```



non cresce negli anni

In [17]:

#3.5 Prendiamo ora in considerazione le biblioteche Affori e Quarto Oggiaro.

#In Figura 1 sono mostrati nella parte alta i grafici del numero totale di nuovi utenti in ciascun anno e nella parte

#bassa la funzione cumulativa, che indica quindi il totale degli utenti della bibliotec a in ciascun anno.

#I grafici della parte bassa della figura sono in ordine giusto? Cioè ciascuno corrispo nde al grafico delle frequenze

#soprastante? Giustificate la risposta.

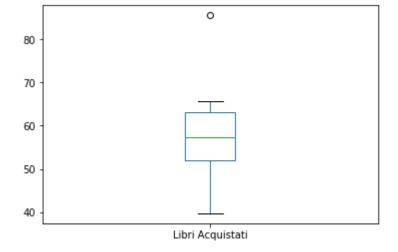
print("Si sono nella giusta corrispondenza. Nel grafico di quarto oggiaro possiamo nota re una forte aumento delle frequenze nell'anno 2002 che si riflette nelle ecdf con un a umento dell'altezza dei gradini")

Si sono nella giusta corrispondenza. Nel grafico di quarto oggiaro possiam o notare una forte aumento delle frequenze nell'anno 2002 che si riflette nelle ecdf con un aumento dell'altezza dei gradini

Esercizio 4

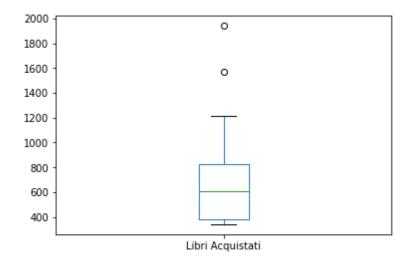
In [18]:

```
#Esercizio 4.1. Tracciare il boxplot oppure l'istogramma (se uno dei due grafici vi sem
bra più rappresentativo) del numero di libri acquisiti in un anno da una biblioteca.
sor = dati[dati['Biblioteca'] == 'Biblioteca Centrale Sormani']
sory = sor[['Anno','Libri Acquistati']].groupby('Anno').sum()
sory.plot.box()
plt.show()
```



In [19]:

#Esercizio 4.2. I grafici del punto precedente rivelano la presenza di alcuni outlier.
#Questi valori sono tutti relativi alla Biblioteca Centrale Sormani.
#Tracciare il boxplot oppure l'istogramma (se uno dei due grafici vi sembra più rappres
entativo) del numero di libri acquisiti in un anno da una biblioteca, escludendo però l
a Biblioteca Centrale Sormani.
no_sor = dati[dati['Biblioteca'] != 'Biblioteca Centrale Sormani']
no_sory = no_sor[['Anno','Libri Acquistati']].groupby('Anno').sum()
no_sory.plot.box()
plt.show()



In [20]:

#Esericizio 4.3.

In [21]:

#Esercizio 4.3.1. Se si esclude la Biblioteca Centrale Sormani si vede che il numero di libri acquisiti annualmente da una biblioteca ha un andamento "a campana": # determinare i parametri di tale distribuzione;

In [22]:

#Esercizio 4.3.2. utilizzare la tecnica del qaplot per controllare se anche il numero d i libri acquisiti annualmente dalla sola Biblioteca Centrale Sormani segue una legge no rmale.

Esercizio 5

5.1.1

$$Var(\overline{X}) = rac{1}{n} Var(X) \ \sqrt{(Var(\overline{X}))} = \sqrt{rac{Var(X)}{n}}$$

5.1.2

$$-rac{100}{rac{1}{\sqrt{n}\sigma}}<rac{\overline{X}-E(X)}{rac{1}{\sqrt{n}}\sigma}<rac{100}{rac{1}{\sqrt{n}\sigma}}$$

$$P(|Z|<rac{100}{rac{1}{\sqrt{n}\sigma}})=0.99$$

Poichè so che σ =90 ottengo:

$$P(|Z|<rac{10\sqrt{n}}{9})=0.99$$

5.1.3 Per il teorema del limite centrale

$$P(Z < rac{10\sqrt{n}}{9}) pprox \Phi(rac{10}{9}\sqrt{n}) - \Phi(-rac{10}{9}\sqrt{n}) = \Phi(rac{10}{9}\sqrt{n}) - (1 - \Phi(rac{10}{9}\sqrt{n})) = 2\Phi(rac{10}{9}\sqrt{n})) -$$

5.2.1

5.2.2

$$n > rac{Var(X)}{\sigma \epsilon^2} = rac{90^2}{0.9*100^2} = ?$$