Tema d'esame di Statistica e analisi dei dati

Prova scritta del 10 giugno 2019

Esercizio 0

- Sia Y una variabile casuale uniforme discreta che assume s valori distinti.
 Fissiamo, solo in questo punto, s = 5.
 - 1.1. Tracciate a mano il grafico della funzione di massa di probabilità di Y. Siate attenti a evidenziare sul grafico tutte le informazioni importanti.
 - 1.2. Tracciate a mano il grafico della funzione di ripartizione di Y. Siate attenti a evidenziare sul grafico tutte le informazioni importanti.
- 2. Sia X una variable bernoulliana di parametro p.

Fissiamo, solo in questo punto, p = 0.8.

- 2.1. Tracciate a mano il grafico della funzione di massa di probabilità di X. Siate attenti a evidenziare sul grafico tutte le informazioni importanti.
- 2.2. Tracciate a mano il grafico della funzione di ripartizione di X. Siate attenti a evidenziare sul grafico tutte le informazioni importanti.
- 2.3. Esprimete il valore atteso e la varianza di X in funzione di p.

Esercizio 1

Sia $\overline{X}_{(n)}$ la media campionaria di un campione casuale X_1, \dots, X_n estratto da una popolazione X bernoulliana di parametro p.

- Esprimete, in funzione di p, il valore atteso di X̄(n).
- 2. Esprimete, in funzione di p e n, la varianza di $\overline{X}_{(n)}$.
- Proponete uno stimatore, chiamiamolo T_n, del valore atteso di X.
- Lo stimatore che avete proposto al punto precedente è non distorto? Giustificate la risposta.
- 5. Proponete uno stimatore non distorto, chiamiamolo U_n , della varianza di X.

Esercizio 2

Siano $0 < \delta < 1$ e $\epsilon > 0$ due valori prefissati.

1. Controllate che la relazione:

$$P(|\overline{X}_{(n)} - p| \le \epsilon) \ge 1 - \delta$$

può essere riscritta nel seguente modo, dove $X_{(n)}^*$ è la media campionaria standardizzata:

$$\mathbb{P}\left(|\overline{X}_{(n)}^*| \leq \frac{\epsilon}{\sqrt{p \cdot (1-p)}} \cdot \sqrt{n}\right) \geq 1 - \delta$$

2. Ipotizzate ora che sia $n \gg 1$.

Sfruttate il teorema del limite centrale e il noto fatto che la varianza di una variabile bernoulliana non può superare il valore 1/4 per controllare che la seguente relazione:

$$P(|\overline{X}_{(n)} - p| \le \epsilon) \ge 1 - \delta$$

equivale, fatte le dovute approssimazioni, a:

$$\Phi(2\epsilon\sqrt{n}) \ge 1 - \delta/2$$
,

dove Φ è la funzione di ripartizione della distribuzione normale standard.

 Fissati δ = 0.05 e ε = 0.01, determinate un valore numerico n₀ tale che, per n > n₀, sia soddisfatta la relazione del punto precedente Φ(2ε√n) ≥ 1 − δ/2. Suggerimento: per fare i conti usate lo strumento di calcolo che avete a disposizione.

Esercizio 3

Collegatevi al sito upload.di.unimi.it, selezionate l'esame di Statistica e analisi dei dati per l'appello odierno e scaricate il file impiantitermici.csv. Questo file contiene le seguenti informazioni raccolte dal Comune di Milano riguardo agli impianti termici installati negli edifici della città:

- IDENTIFICATIVO_IMPIANTO: identificatore dell'impianto;
- GENERATORI_NUMERO: numero di generatori dell'impianto;
- EDIFICIO_CATEGORIA: categoria catastale dell'edificio;
- GENERATORE_POTENZA: potenza del generatore, espressa in kW;
- GENERATORE_COMBUSTIBILE: tipo di combustibile utilizzato;
- GENERATORE_DATA_INST: anno di installazione;
- RAPPORTO_DI_CONTROLLO_DATA: anno in cui è stato fatto il controllo dell'impianto;
- RAP_DI_CONTROLLO_ESITO: esito del controllo;
- ISPEZIONE_DATA: anno in cui è stata effettuata l'ispezione dell'impianto;
- ISPEZIONE ESITO: esito dell'ispezione.

In questo file il carattere ";" separa le colonne e i numeri reali sono stati registrati usando il carattere "," come separatore dei decimali.

- 1. Quanti cusi contiene il dataset?
- Il carattere GENERATORE_POTENZA è nominale, ordinale o scalare?
- Quanti impianti sono stati installati prima del 1940?
- Memorizzate in una variabile chiamata selezione i casi in cui la potenza dell'impianto di riscaldamento è tra 15 e 35 kW (estremi esclusi) e il combustibile utilizzato è il GAS NATURALE.
- Quanto vale in questa selezione l'eterogeneità del carattere GENERATORE_COMBUSTIBILE? (Suggerimento: non è necessario fare conti)
- 6. Nella selezione effettuata quante sono le diverse categorie di edifici?
- 7. Nella selezione effettuata qual è la moda del carattere EDIFICIO_CATEGORIA?
- 8. Nella selezione effettuata quanti sono gli edifici di categoria E1?
- Quale percentuale della selezione effettuata corrisponde agli edifici considerati nel punto precedente?

Esercizio 4

Memorizzate in una variabile chiamata selezione gli impianti installati dopo l'anno 2000 e prima del 2019, e utilizzate solo questi dati per rispondere alle domande del presente esercizio.

- Tracciate un grafico del carattere GENERATORE_DATA_INST che convinca del fatto che, a partire dall'anno 2001 e fino al 2018, ogni anno è stato installato circa lo stesso numero di impianti.
- Quanto vale in questa selezione l'eterogeneità del carattere GENERATORE_DATA_INST? (Suggerimento: non è necessario fare conti)
- Calcolate la tabella delle frequenze relative del carattere ISPEZIONE_ESITO.
- Calcolate la tabella delle frequenze relative del carattere ISPEZIONE_ESITO facendovi
 comparire anche i valori mancanti.
- 5. Qual è la percentuale di impianti ispezionati che ha ottenuto un esito positivo dell'ispezione?
- 6. L'impianto termico del mio condominio è stato installato qualche anno fa, ricordo che era un anno successivo al 2000. Non è ancora stato ispezionato. Si fornisca una stima della probabilità p che, quando verrà ispezionato, l'impianto ottenga un esito positivo.
- 7. Qual è la taglia del campione che avete utilizzato nella stima del punto precedente?
- 8. Quale stimatore T_n avete utilizzato per stimare p?
- 9. Si fornisca una condizione sufficiente per la taglia n del campione affinché non sia inferiore a 0.95 la probabilità $P(|T_n-p|\leq 0.01)$.